XỬ LÝ ẢNH SỐ

Chương 8

Nhận dạng ảnh

Nội dung

- Nhận dạng ảnh: bài toán, thách thức, hệ thống nhận dạng
  - Học có giám sát và không giám sát
- Trích chọn đặc trưng: màu, kết cấu, hình dạng, cục bộ
- Nhận dạng dựa theo không gian
  - K-means, khoảng cách lớn nhất, ISODATA, Mean-Shift
  - k láng giềng (kNN), mô hình túi từ, đánh giá
- Nhận dạng theo cấu trúc
- Một số mô hình mạng nơ ron
  - Mạng Hopfield, mạng Kohonen, hướng tới CNN

Quá trình nhận dạng

- Quá trình nhận dạng dựa vào những mẫu học biết trước: Học có giám sát; ngược lại: Học không giám sát
- Quá trình nhận dạng
  - Lựa chọn mô hình biểu diễn đối tượng
  - Lựa chọn luật ra quyết định (phương pháp nhận dạng) và suy diễn quá trình học
  - Học nhận dạng
- Khi mô hình biểu diễn đã được xác định
  - Mô hình tham số
  - Mô hình cấu trúc
- Đến quá trình học nhằm cải thiện, điều chỉnh việc phân lớp
- Nhận dạng là tìm ra quy luật và thuật toán để gán đối tượng vào lớp của nó

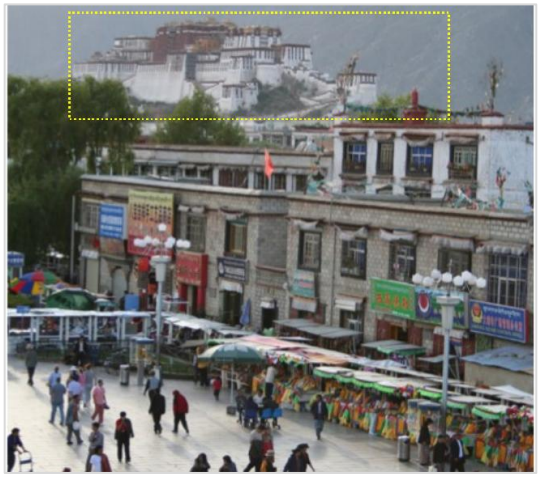
Các bài toán thị giác ngữ nghĩa



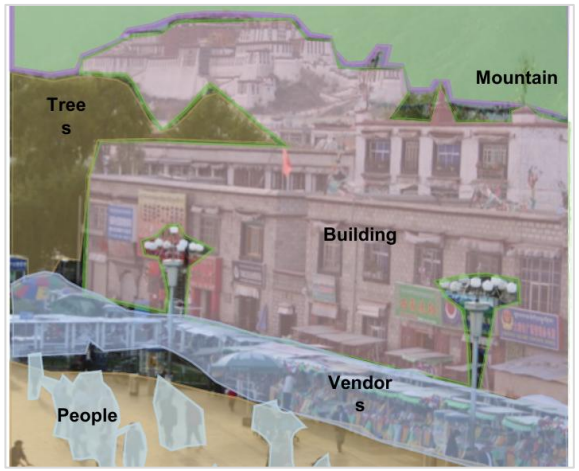
Phân lớp: có đèn giao thông?



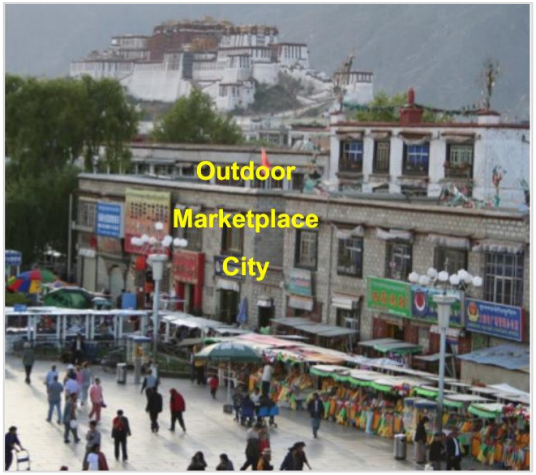
Phát hiện: người ở đâu?



Định danh: có phải Potala?



Phân vùng ngữ nghĩa



Phân lớp khung cảnh



Nhận dạng hành động

Nguồn hình: K. Grauman, CS376, UT Austin; I. Gkioulekas, 16-385, CMU

Vì sao nhận dạng ảnh khó?



Góc nhìn



Chiếu sáng



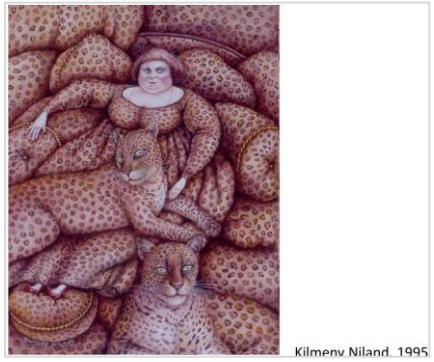
Kích thước



Biến dạng



Che khuất



Nền phức tạp



Đa dạng trong lớp



10.000 – 30.000 lớp

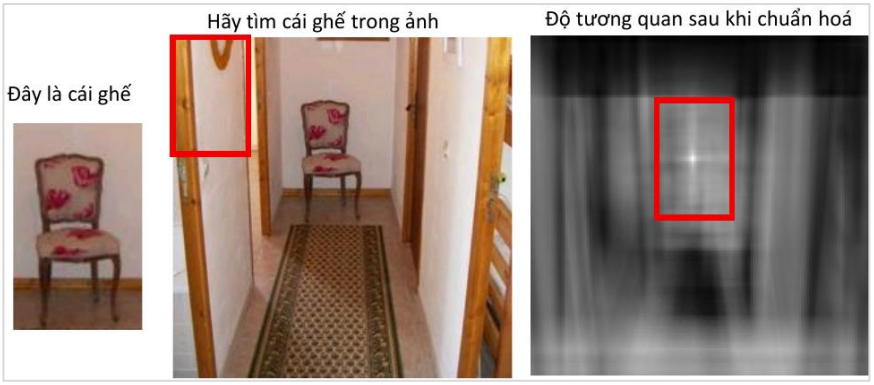
Nguồn hình: K. Grauman, CS376, UT Austin; I. Gkioulekas, 16-385, CMU

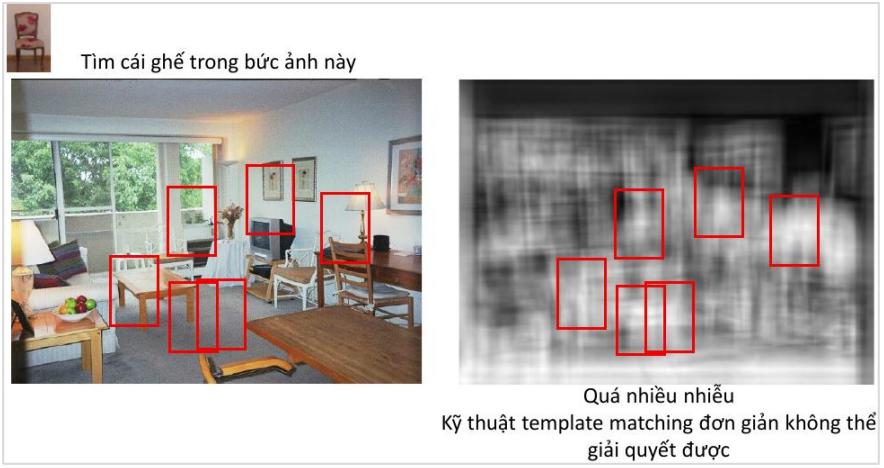
Giới hạn của so khớp mẫu
Template matching

- Trượt ảnh mẫu T trên ảnh I, tại mỗi vị trí tính tương quan chuẩn hóa (NCC):

$$NCC = \frac{\Sigma(I - \bar{I})(T - \bar{T})}{\sqrt{\left[\Sigma (I - \bar{I})^2 \cdot \Sigma \left(T - \bar{T}\right)^2\right]}}$$

  - NCC ∈ [−1, 1]; bất biến với thay đổi độ sáng tuyến tính a·I + b
- Tốt khi đối tượng giống hệt mẫu: cùng góc nhìn, kích thước, hình dáng
- Thất bại khi đối tượng biến đổi hoặc nền phức tạp → cần đặc trưng bất biến + bộ phân lớp học từ dữ liệu





Nguồn hình: K. Grauman, CS376, UT Austin; I. Gkioulekas, 16-385, CMU

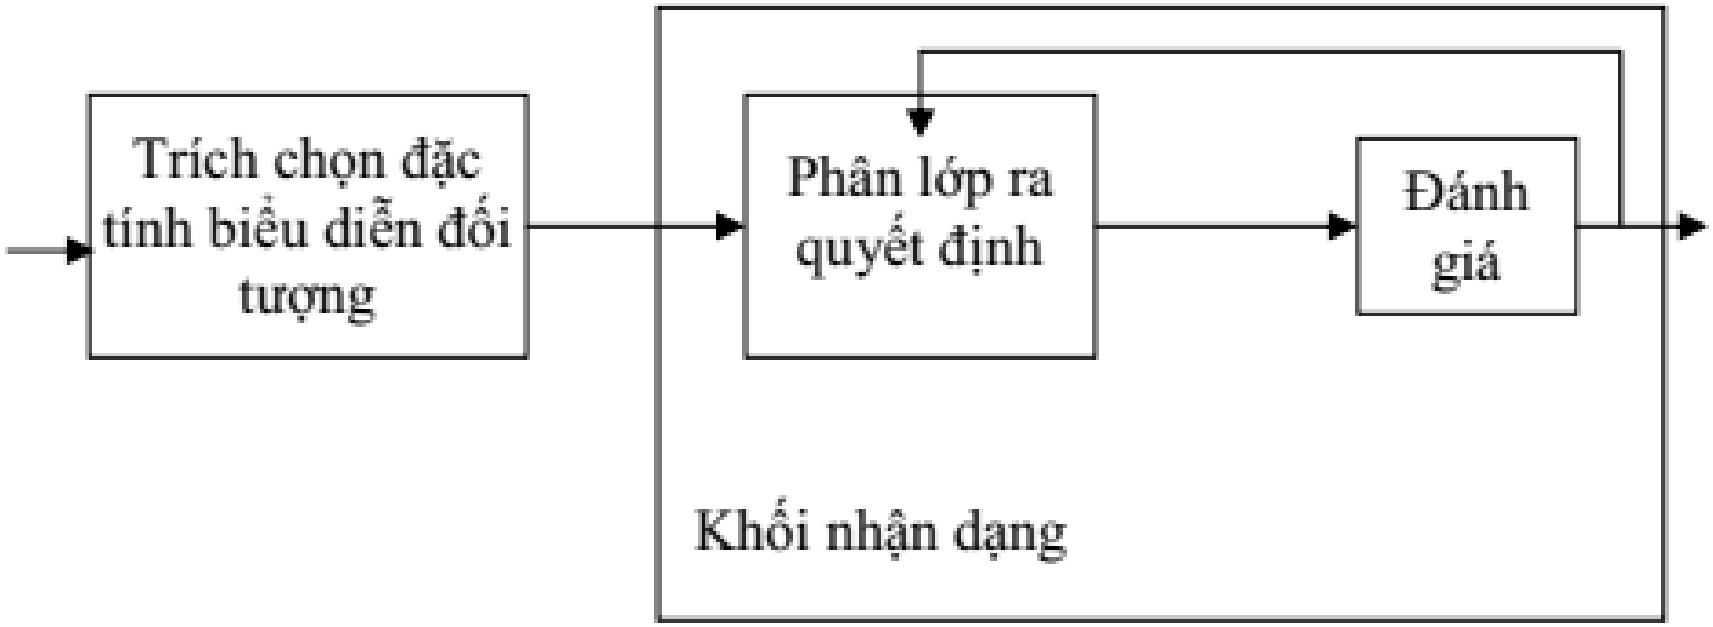
Học có giám sát
supervised learning

- Học có giám sát – supervised learning: dựa vào kiến thức biết trước.
- Sử dụng một thư viện mẫu chuẩn.
- Mẫu cần nhận dạng sẽ được so sánh với mẫu chuẩn để xác định mẫu đang đánh giá thuộc loại nào.
- Vấn đề chủ yếu là thiết kế hệ thống có thể so sánh đối tượng với mẫu nên tương đối rõ ràng về kết quả và dễ đánh giá hiệu quả

Học không giám sát
unsupervised learning

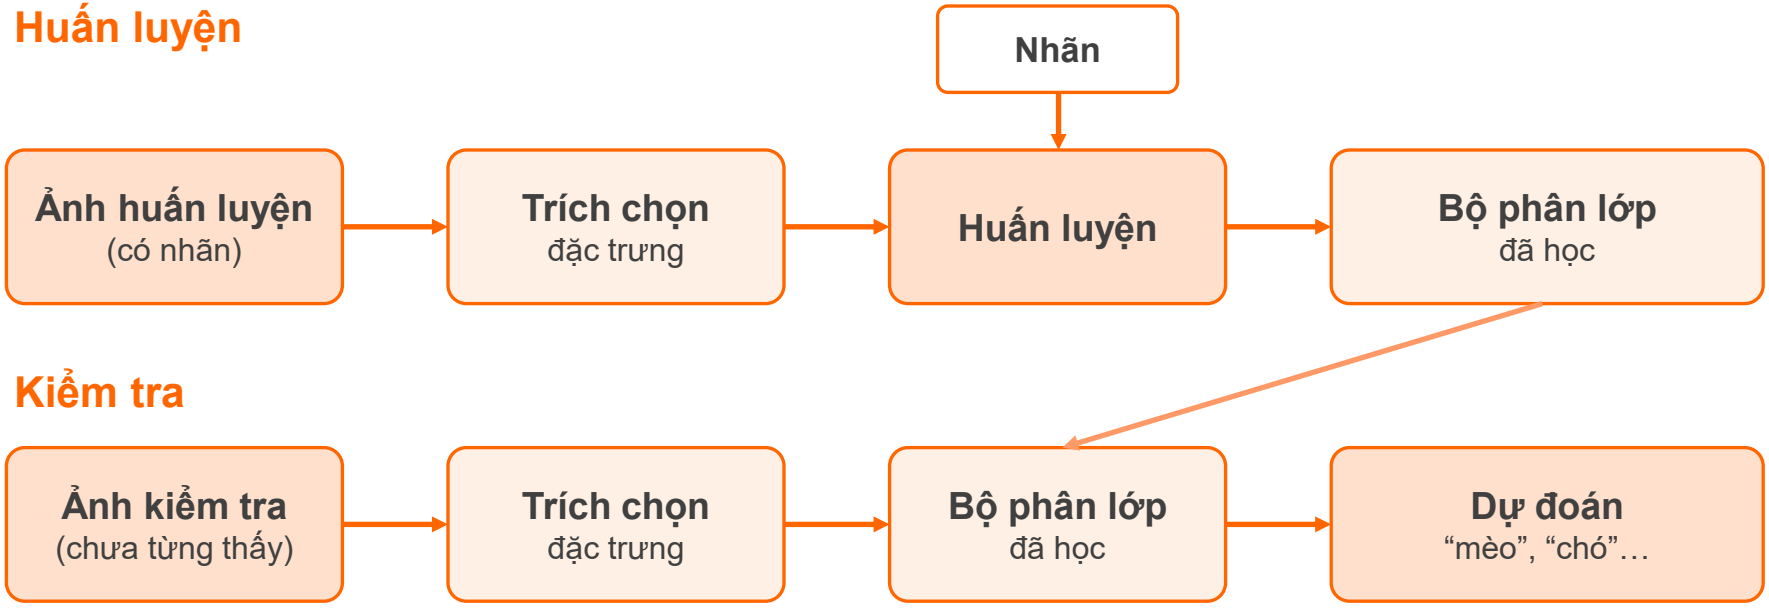
- Học không giám sát phải tự định ra các lớp khác nhau và xác định đặc trưng của từng lớp
- Khó khăn để xác định tính chính xác: số lớp, những đặc trưng của các lớp đối tượng trong kiểu học này vì không có thư viện mẫu để so sánh
- Học không giám sát được phát triển nhằm gộp các nhóm theo một cách tối ưu.

Cấu trúc 1 hệ thống nhận dạng



Tiếp cận dựa trên dữ liệu

Huấn luyện và kiểm tra bộ phân lớp



- Thu thập bộ dữ liệu ảnh kèm nhãn lớp
- Huấn luyện: dùng một thuật toán học để xây bộ phân lớp từ (đặc trưng, nhãn)
- Kiểm tra: đánh giá trên ảnh không dùng khi huấn luyện; trích đặc trưng giống hệt khi huấn luyện

Nhận dạng dựa theo không gian

- Trong kỹ thuật này thì đối tượng được biểu diễn bằng một vector nhiều chiều.
- Mỗi chiều là một tham số thể hiện một đặc điểm của đối tượng đó
- Một số khái niệm
  - Phân hoạch không gian
  - Hàm phân lớp hoặc hàm ra quyết định

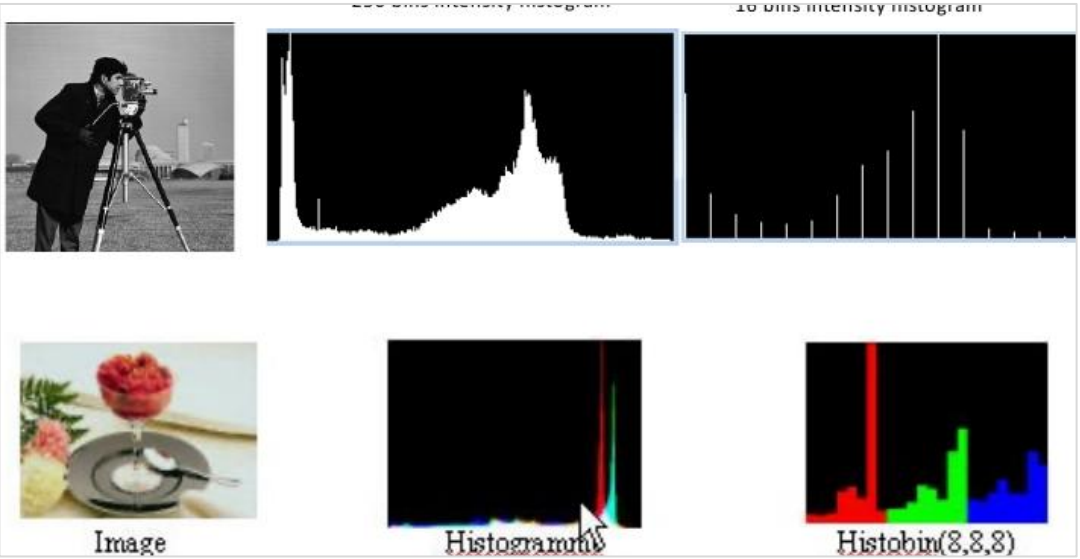
Trích chọn đặc trưng

Đặc trưng toàn cục và đặc trưng cục bộ

	Đặc trưng toàn cục	Đặc trưng cục bộ
Mô tả	Cả ảnh / cả đối tượng như một khối	Từng vùng nhỏ quanh các điểm đặc trưng
Ví dụ	Màu (lược đồ), kết cấu (GLCM), hình dạng (mômen Hu, độ tròn), HOG	SIFT, SURF, LBP, ORB, BRISK, FREAK
Số vector	Một vector cố định cho mỗi ảnh	Hàng trăm – hàng nghìn vector, số lượng thay đổi theo ảnh
Ưu điểm	Gọn, tính nhanh, dùng ngay với bộ phân lớp	Bền với che khuất, nền phức tạp; bất biến tỉ lệ, phép quay
Nhược điểm	Nhạy với nền, che khuất, biến dạng	Phải gom lại thành một vector (VD: mô hình túi từ)

Đặc trưng tốt: phân biệt được các lớp · bất biến với biến đổi không quan trọng · gọn · tính nhanh

Đặc trưng màu: lược đồ



- Lược đồ mức xám hoặc lược đồ màu (VD 8×8×8 bin cho R, G, B)
- Chuẩn hóa: chia cho tổng số điểm ảnh

Ưu điểm

- Đơn giản, tính nhanh
- Bất biến với phép dịch, quay, co giãn
- Bền với biến dạng nhẹ

Nhược điểm

- Bỏ qua vị trí không gian
- Không tính tương đồng giữa các bin gần nhau
- Bị ảnh hưởng bởi nền, ánh sáng

So sánh hai lược đồ: khoảng cách L1, giao lược đồ $\Sigma \min(h_1, h_2)$, χ^2

Đặc trưng kết cấu: GLCM

Ma trận đồng hiện mức xám (Haralick, 1973)

- Đếm số cặp điểm ảnh (p_1, p_2), p_2 cách p_1 một khoảng d theo hướng θ, có mức xám (i, j):

$$C(i, j) = \#\{(p_1, p_2): I(p_1) = i, I(p_2) = j\}$$

- Kích thước Ng × Ng (Ng: số mức xám, thường giảm xuống 8, 16, 32)
- Mỗi cặp (d, θ) cho một ma trận: θ = 0°, 45°, 90°, 135°; d = 1, 2, 3…
- Chuẩn hóa P(i, j) = C(i, j) / tổng

Ảnh 4×4 (3 mức xám)

0	0	1	1
0	0	1	1
0	2	2	2
2	2	1	1

GLCM, d = 1, θ = 0° (sang phải)

i \ j	0	1	2
0	2	2	1
1	0	3	0
2	0	1	3

Tổng 12 cặp. Kết cấu mịn, đồng nhất → giá trị lớn dồn về đường chéo; kết cấu thô, tương phản cao → giá trị trải xa đường chéo

Các đặc trưng Haralick

Rút gọn GLCM thành vài con số

Đặc trưng	Công thức	Ý nghĩa	Ví dụ
Năng lượng (energy)	$\Sigma\, P(i, j)^2$	Lớn khi kết cấu đều, lặp lại	0,194
Entropy	$-\Sigma\, P(i, j) \cdot \log_2 P(i, j)$	Lớn khi kết cấu hỗn loạn	2,459
Tương phản (contrast)	$\Sigma\, (i - j)^2 \cdot P(i, j)$	Lớn khi mức xám lân cận chênh lệch nhiều	0,583
Đồng nhất (homogeneity)	$\Sigma\, P(i, j) / (1 + (i - j)^2)$	Lớn khi giá trị dồn về đường chéo	0,808

- Cột ví dụ: tính từ GLCM ở phần trước, P = C / 12
- Haralick đề xuất 14 đặc trưng; ghép nhiều (d, θ) → vector kết cấu, lấy trung bình 4 hướng để gần bất biến với phép quay

Đặc trưng hình dạng

Đặc trưng hình học và mômen ảnh

- Hình học
  - Diện tích A, chu vi P, tỉ số dài/rộng, độ tròn $C = 4\pi A / P^2$ (hình tròn: C = 1, hình vuông: C ≈ 0,785)
- Mômen ảnh bậc (p + q)

$$M(p,q) = \Sigma_x \Sigma_y x^p \cdot y^q \cdot I(x,y)$$

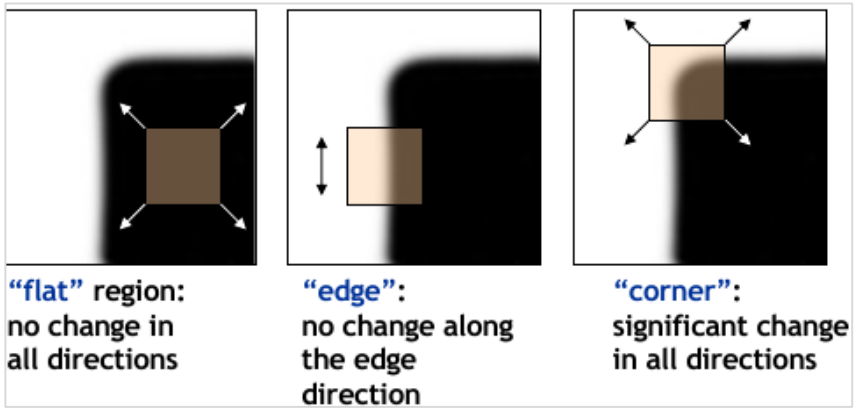
  - M(0,0) = diện tích; trọng tâm $\bar{x}$ = M(1,0) / M(0,0), $\bar{y}$ = M(0,1) / M(0,0)
- Mômen trung tâm → bất biến với phép dịch

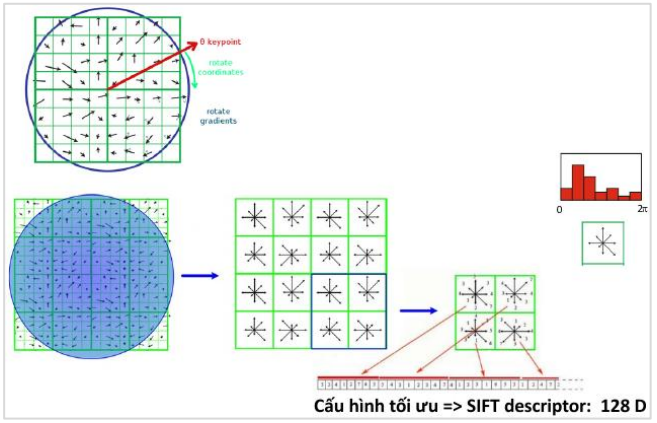
$$\mu(p,q) = \Sigma_x \Sigma_y (x - \bar{x})^p \cdot (y - \bar{y})^q \cdot I(x,y)$$

  - Chuẩn hóa $\eta(p,q) = \frac{\mu(p,q)}{\mu(0,0)^{1+\frac{p+q}{2}}}$ → bất biến tỉ lệ
  - 7 mômen Hu (1962) → bất biến dịch, tỉ lệ, quay;
    VD $\varphi_1 = \eta(2,0) + \eta(0,2)$
  - Hướng trục chính: $\theta = \frac{1}{2} \cdot \text{atan2}\left(2\mu(1,1), \mu(2,0) - \mu(0,2)\right)$

Đặc trưng cục bộ

Điểm đặc trưng và bộ mô tả SIFT





- Phát hiện điểm đặc trưng: góc Harris (dịch cửa sổ theo mọi hướng, cường độ đều thay đổi mạnh), DoG / SIFT, FAST…
- Mô tả vùng quanh điểm: SIFT chia vùng 16×16 thành 4×4 ô, mỗi ô lược đồ hướng gradient 8 bin → vector 4×4×8 = 128 chiều
- Bất biến tỉ lệ và phép quay (chuẩn theo hướng chính); bền với thay đổi chiếu sáng (chuẩn hóa vector)
- Ứng dụng: so khớp ảnh, ghép ảnh toàn cảnh, nhận dạng đối tượng, mô hình túi từ

Nguồn hình: A. Efros; D. Lowe, IJCV 2004

Phân hoạch không gian

- Giả sử không gian đối tượng X được biểu diễn bởi m vector X_i :

$$X = \{X_i, i = 1,2,...,m\}$$

- P được gọi là 1 phân hoạch không gian X thành các lớp $C_i, C_i \subset X$ sao cho

$$C_i \cap C_j = \emptyset \quad i \neq j, \bigcup_{i=1}^{m} C_i = X$$

- Trong trường hợp thông thường thì không gian chỉ có thể được phân tách từng phần

Hàm phân lớp

- Để phân đối tượng ra các lớp ta cần xác định số lớp và ranh giới giữa các lớp đó
- Hàm phân lớp sẽ giúp phân biệt các lớp
- Với k lớp cần k hàm phân lớp (tương đương k−1 hàm độc lập; 2 lớp chỉ cần 1 hàm)

Hàm phân lớp

- Gọi $\{g_i\}$ là lớp các hàm phân lớp. Lớp hàm này được định nghĩa như sau:

  Nếu $\forall\ i \neq k$, $g_k(X) > g_i(X)$ thì ta quyết định:

  $\Rightarrow$ $X \in$ lớp k.

- Như vậy để phân biệt k lớp, dùng k hàm phân biệt (k−1 hàm độc lập).
- Hàm phân lớp g thường là hàm tuyến tính:

$$g(X) = W_0 + W_1 X_1 + \ldots + W_k X_k$$

Trong đó:

W_i là các trọng số gán cho các thành phần X_i.

W_0 là trọng số hiệu chỉnh.

Hàm phân lớp

- Nếu g là tuyến tính, ta nói việc phân lớp là tuyến tính hay siêu phẳng (Hyperplane).
- Các hàm phân biệt thường được xây dựng dựa trên khái niệm khoảng cách hay dựa vào xác suất có điều kiện.
- Theo khoảng cách: Nếu khoảng cách giữa 2 đối tượng nhỏ hơn một ngưỡng τ nào đấy thì coi 2 đối tượng là giống nhau và gộp chúng vào một lớp. Ngược lại, nếu khoảng cách lớn hơn ngưỡng, có nghĩa là chúng khác nhau và tách thành 2 lớp.

Thuật toán nhận dạng không gian
(Phân cụm và phân lớp)

- Một số thuật toán tiêu biểu
  - Thuật toán k trung bình (K-means)
  - Thuật toán dựa vào khoảng cách lớn nhất
  - Thuật toán ISODATA
  - Thuật toán Mean-Shift
  - Thuật toán k láng giềng (k-nearest neighbour) – học có giám sát

Thuật toán nhận dạng không gian
(Tự học – Unsupervised learning)

- Thuật toán k trung bình (k - means)
  - Khởi tạo K tâm: K phần tử đầu tiên hoặc chọn ngẫu nhiên (K cho trước)
  - Tìm K cụm sao cho tổng bình phương khoảng cách từ các phần tử tới tâm cụm của chúng là nhỏ nhất
  - Công thức tâm cụm (N: số phần tử của cụm C_k):

$$Z_k = \frac{1}{N}\sum_{j=1}^{N} X_j, \qquad X_j \in C_k$$

Thuật toán nhận dạng không gian
(Tự học – Unsupervised learning)

- Thuật toán k trung bình: các bước

1. Chọn ngẫu nhiên K tâm (centroid) cho K cụm (cluster). Mỗi cụm được đại diện bằng các tâm của cụm.
2. Tính khoảng cách giữa các đối tượng đến K tâm (thường dùng khoảng cách Euclid).
3. Nhóm các đối tượng vào nhóm gần nhất.
4. Xác định lại tâm mới cho các nhóm.
5. Thực hiện lại bước 2 cho đến khi không có sự thay đổi nhóm nào của các đối tượng.

Ví dụ: K-means trên mức xám

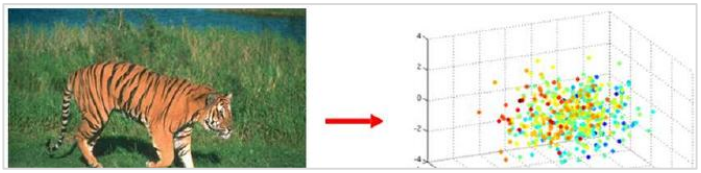
Dữ liệu: 6 mức xám {12, 18, 25, 140, 160, 200}; K = 2; tâm ban đầu = 2 phần tử đầu: 12 và 18

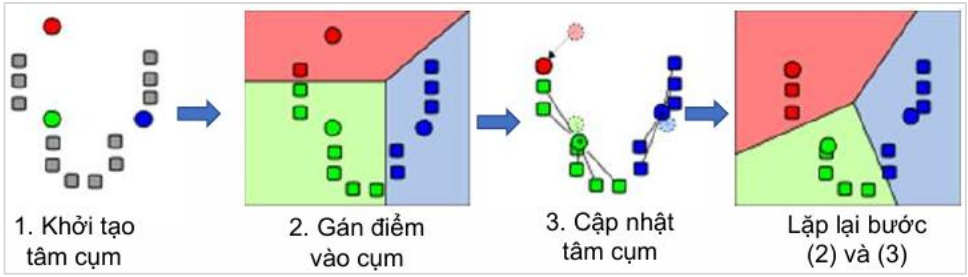
Vòng	Tâm hiện tại	Cụm 1	Cụm 2	Tâm mới
1	12; 18	{12}	{18, 25, 140, 160, 200}	12; 108,6
2	12; 108,6	{12, 18, 25}	{140, 160, 200}	18,33; 166,67
3	18,33; 166,67	{12, 18, 25}	{140, 160, 200}	Không đổi → dừng

- Vòng 2: 18 cách tâm 1 là 6, cách tâm 2 là 90,6 → chuyển sang cụm 1; 25 cũng chuyển
- J cuối = $(12 - 18{,}33)^2 + \ldots + (200 - 166{,}67)^2 \approx 1951{,}3$
- Ranh giới hai cụm = trung điểm hai tâm ≈ 92,5 → K-means với K = 2 trên mức xám chính là một cách tự tìm ngưỡng nhị phân, gần với ý tưởng Otsu

K-means trong phân vùng ảnh

- Mỗi điểm ảnh là một vector: mức xám (1 chiều), màu RGB (3 chiều), màu + vị trí (x, y) (5 chiều)
- Phân cụm các vector → mỗi cụm là một vùng; thay mỗi điểm ảnh bằng tâm cụm của nó → ảnh còn K màu

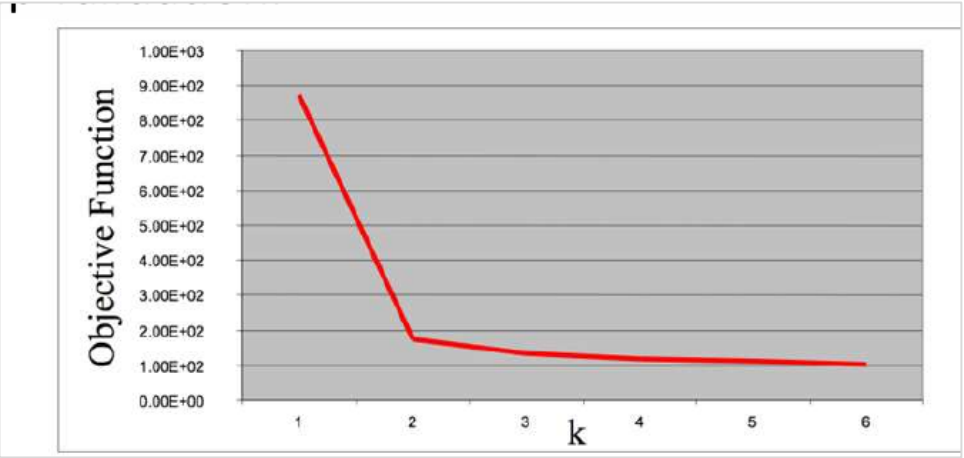






Chọn số cụm K

Phương pháp khuỷu tay (elbow)



Ví dụ 6 mức xám

K	J
1	34 955,5
2	1 951,3
3	284,7
6	0

- J luôn giảm khi K tăng (K = N thì J = 0) → không chọn K theo J nhỏ nhất
- Chọn K tại "khuỷu tay": sau điểm đó J giảm chậm hẳn → ví dụ trên: K = 2
- Cách khác: thử nhiều K và đánh giá trên tập kiểm định; hoặc chọn K theo yêu cầu ứng dụng (VD số màu cần giữ lại)

K-means: ưu điểm và hạn chế

- Ưu điểm
  - Đơn giản, dễ cài đặt
  - Nhanh: mỗi vòng O(K·N·d)
  - Luôn hội tụ (J không tăng)
  - Dùng làm bước trung gian: phân vùng, học từ điển (BoW)
- Hạn chế
  - Phải chọn trước K
  - Hội tụ về cực tiểu cục bộ, phụ thuộc khởi tạo
  - Nhạy với điểm ngoại lai
  - Chỉ hợp cụm dạng cầu, kích thước tương đương
  - Phụ thuộc thang đo của đặc trưng

Cải tiến thường dùng

Chạy nhiều lần với khởi tạo khác nhau, giữ lần có J nhỏ nhất

K-means++: chọn tâm tiếp theo với xác suất tỉ lệ bình phương khoảng cách tới tâm gần nhất

Chuẩn hóa đặc trưng trước khi phân cụm

Thuật toán nhận dạng không gian
(Tự học – Unsupervised learning)

- Thuật toán Khoảng cách lớn nhất: Với một tập gồm m đối tượng:
  - Khoảng cách giữa các đối tượng có thể được xác định như là đại lượng để phân lớp
  - Khoảng cách lớn nhất ứng với phần tử xa nhất tạo nên lớp mới
  - Sự phân lớp sẽ hình thành dần dần dựa vào việc tính khoảng cách giữa các đối tượng và các lớp

Thuật toán nhận dạng không gian
(Tự học – Unsupervised learning)

- Thuật toán Khoảng cách lớn nhất: các bước

Bước 1:

Chọn hạt nhân ban đầu: $X_i \in C_1$ là lớp ứng với hàm g_1 với Z_1 là phần tử trung tâm (phần tử có khoảng cách trung bình tới các phần tử khác trong g_1)

Tính tất cả các khoảng cách $D_{j1} = D(X_j, Z_1)$ với j=1..m

Tìm D_{k1} lớn nhất. X_k là phần tử xa nhất của nhóm g_1, X_k trở thành phần tử trung tâm Z_2 của lớp mới g_2.

Tính $d_1=D_{12}=D(Z_1, Z_2)$

Thuật toán nhận dạng không gian
(Tự học – Unsupervised learning)

- Thuật toán Khoảng cách lớn nhất: các bước

Bước 2:

Tính các khoảng cách D_{j1}, D_{j2} với j=1..m

Đặt $D_k = \max_j \min(D_{j1}, D_{j2})$: khoảng cách lớn nhất từ một phần tử tới tâm gần nhất của nó

Điều kiện kết thúc

Nếu $D_k < \theta d_1$ kết thúc thuật toán (phân lớp xong)Nếu không sẽ tạo nên lớp g_3 có X_k là phần tử trung tâm Z_3

Tính $d_3=(D_{12}+D_{13}+D_{23})/3$

Lặp đến khi thỏa đk kết thúc; cuối cùng gán mỗi phần tử vào lớp có tâm gần nhất

Ví dụ: thuật toán khoảng cách lớn nhất

A(0;0), B(1;0), C(0;1), D(8;8), E(9;8), F(0;9); Z_1 = A; θ = 0,5

Điểm	Vòng 1: d tới A	Vòng 2: min d tới {A, E}	Vòng 3: min d tới {A, E, F}
A	0	0	0
B	1	1	1
C	1	1	1
D	11,31	1	1
E	12,04	0	0
F	9	9	0
Quyết định	max = 12,04 (E) → Z_2 = E; d_1 = 12,04	9 > 0,5·12,04 = 6,02 → Z_3 = F; d = 10,03	1 < 0,5·10,03 = 5,02 → dừng

Kết quả: {A, B, C}, {D, E}, {F}. Với θ = 0,95: 9 < 11,44 → dừng ngay, chỉ 2 lớp
θ là "núm vặn" số lớp; F đứng riêng → thuật toán nhạy với điểm nhiễu

Thuật toán nhận dạng không gian
(Tự học – Unsupervised learning)

- Thuật toán Isodata:
  - ISODATA: Iterative Self Organizing Data Analysis
  - Thuật toán này tương đối mềm dẻo và không cố định các lớp

Thuật toán nhận dạng không gian
(Tự học – Unsupervised learning)

- Thuật toán Isodata: các bước

- Lựa chọn phân hoạch dựa vào các tâm bất kỳ (ít phụ thuộc vào tâm ban đầu hơn K-means)

- Phân vùng bằng cách đặt các điểm vào lớp có tâm gần nhất dựa vào khoảng cách

- Tách đôi lớp có độ lệch chuẩn lớn hơn ngưỡng t_1

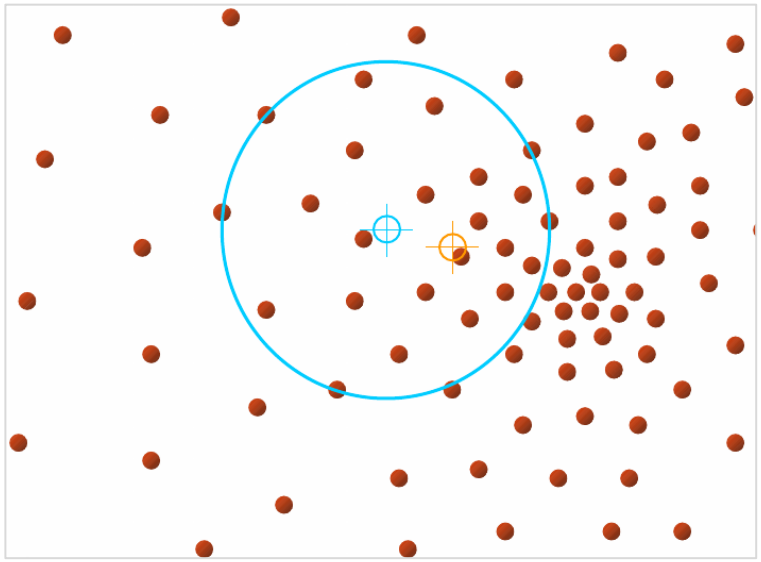
- Xác định phân hoạch mới dựa vào các tâm vừa xác định cho đến khi không có tâm mới

- Gộp hai lớp có khoảng cách giữa hai tâm nhỏ hơn ngưỡng t_2

Lặp các bước trên cho đến khi thỏa mãn tiêu chuẩn phân hoạch.

Mean-Shift

Phân cụm không cần biết trước K



- Ý tưởng: cụm = vùng quanh một đỉnh (mode) của mật độ dữ liệu
- B1: đặt cửa sổ bán kính h tại một điểm
- B2: tính trọng tâm (mean) các điểm trong cửa sổ
- B3: dịch cửa sổ tới trọng tâm (vector mean-shift)
- B4: lặp tới khi hội tụ; các điểm hội tụ về cùng đỉnh thuộc một cụm

Ví dụ 1 chiều: dữ liệu {1, 2, 3, 7, 8}, h = 2

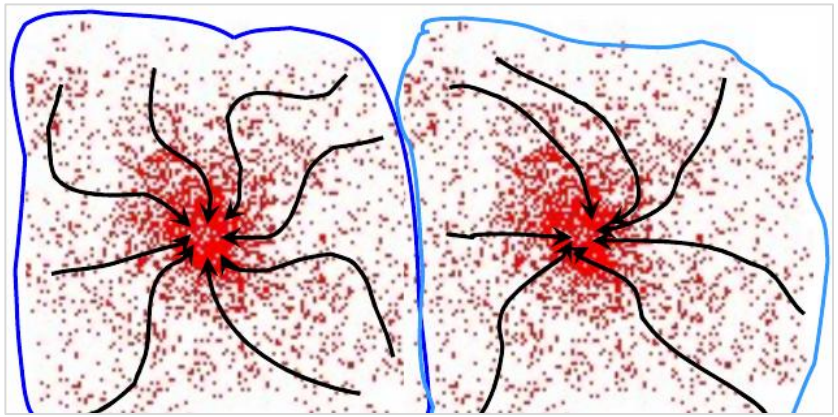
Bắt đầu tại 4: cửa sổ [2; 6] chứa {2, 3} → 2,5 → [0,5; 4,5] chứa {1, 2, 3} → 2 → không đổi

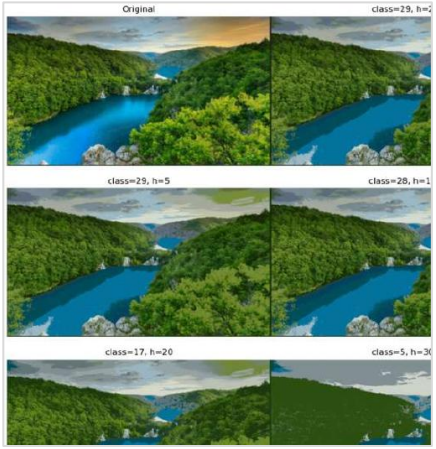
Bắt đầu tại 6: cửa sổ [4; 8] chứa {7, 8} → 7,5 → không đổi

→ 2 đỉnh (2 và 7,5) ⇒ 2 cụm, không cần cho trước K

Nguồn hình: Thị giác máy tính – Bài 10: Phân đoạn ảnh (theo Y. Ukrainitz & B. Sarel)

Mean-Shift: vùng hút và ứng dụng





Ưu điểm	Nhược điểm
Không cần biết trước số cụm	Kết quả phụ thuộc bán kính h; chọn h không dễ
Cụm có hình dạng bất kỳ	Tính toán chậm (mỗi bước duyệt nhiều điểm)
Ít bị ảnh hưởng bởi điểm ngoại lai	Khó mở rộng khi số chiều đặc trưng lớn
Chỉ một tham số h	

Thuật toán nhận dạng không gian
(Học có giám sát – Supervised learning)

- **Thuật toán k láng giềng**:
  - Thuật toán này dựa vào vị trí của đối tượng cần xét để xác định lớp mà đối tượng đó thuộc về là lớp nào
  - Các mẫu sẽ được biểu diễn trên không gian đối tượng
  - Mỗi đối tượng cần xác định lớp sẽ tìm k mẫu gần nhất xung quanh
  - Đối tượng đầu vào này sẽ thuộc lớp có số lượng lớn nhất trong số k láng giềng

Thuật toán nhận dạng không gian
(Học có giám sát – Supervised learning)

- Thuật toán k láng giềng:
  - Vì thuật toán chọn số đông để quyết định việc phân lớp nên thông thường lớp lớn nhất trong tập mẫu thường có xu hướng thống trị
  - Để làm giảm việc này thì trọng số liên quan đến khoảng cách có thể được thêm vào, và mẫu càng xa sẽ có ảnh hưởng ít hơn so với mẫu ở gần

Ví dụ: kNN phân loại hạt gạo

Đặc trưng: (chiều dài, chiều rộng) mm; hạt cần nhận dạng Q = (5,0; 2,4)

Thứ hạng	Mẫu	(dài; rộng)	Lớp	Khoảng cách tới Q
1	G2	(4,0; 2,0)	gãy	1,08
2	N3	(6,2; 3,0)	nguyên	1,34
3	G1	(3,5; 1,8)	gãy	1,62
4	N1	(6,5; 3,2)	nguyên	1,70
5	G3	(3,2; 1,5)	gãy	2,01
6	N2	(6,8; 3,4)	nguyên	2,06

k = 1: G2 → gãy k = 3: 2 gãy, 1 nguyên → gãy k = 5: 3 gãy, 2 nguyên → gãy
k = 2: 1 – 1 → hòa ⇒ với 2 lớp nên chọn k lẻ
Chuẩn hóa đặc trưng nếu các chiều có đơn vị / thang đo khác nhau

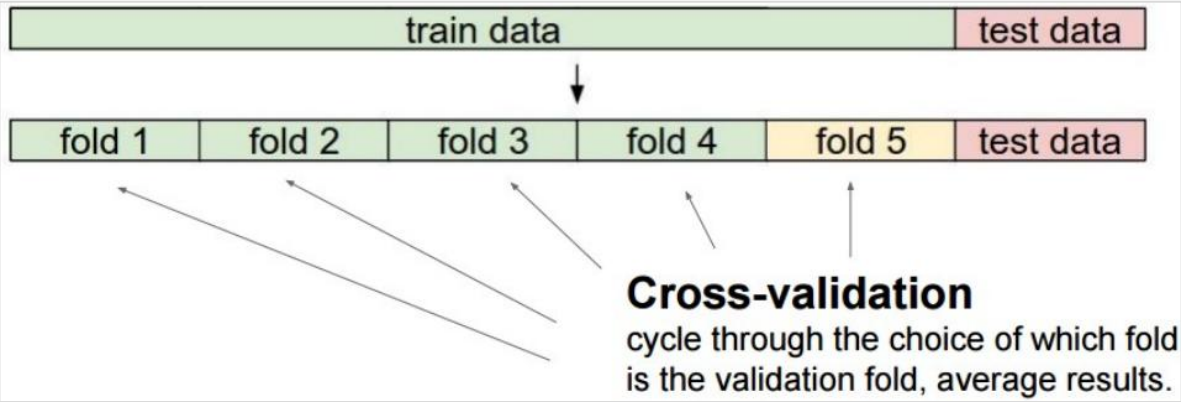
kNN: độ đo khoảng cách

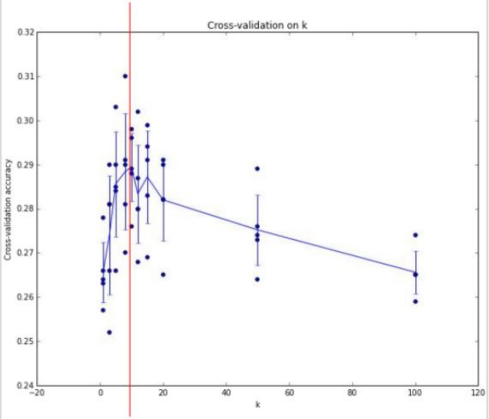
Độ đo	Công thức	Thường dùng khi
Euclid (L2)	$d = \sqrt{\Sigma (x_i - y_i)^2}$	Đặc trưng liên tục, cùng thang đo
Manhattan (L1)	$d = \Sigma \lvert x_i - y_i \rvert$	Ít nhạy với chênh lệch lớn ở một chiều
Minkowski (Lp)	$d = (\Sigma \lvert x_i - y_i \rvert^p)^{(1/p)}$	Tổng quát: p = 1 → L1, p = 2 → L2
Cosine	$d = 1 - x \cdot y / (\lVert x \rVert \cdot \lVert y \rVert)$	Vector tần suất (BoW), quan tâm hướng
Chi bình phương (χ^2)	$d = \frac{1}{2} \Sigma (x_i - y_i)^2 / (x_i + y_i)$	So sánh lược đồ

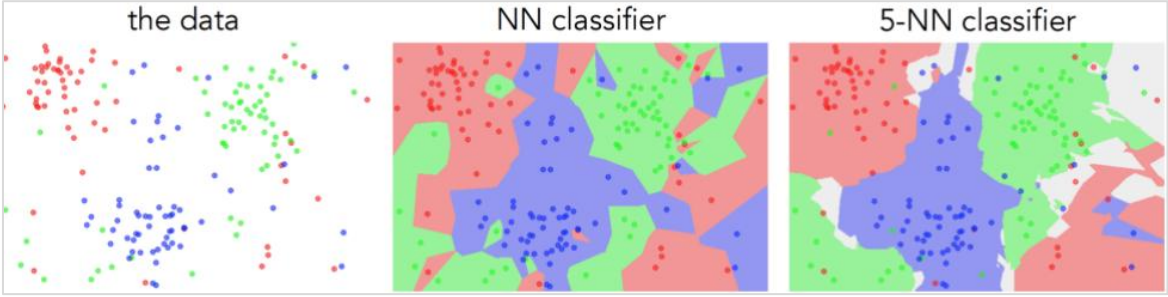
- Chuẩn hóa trước khi tính khoảng cách
  - Min–max: $x' = (x - \min) / (\max - \min) \rightarrow [0; 1]$
  - Z-score: $x' = (x - \mu) / \sigma \rightarrow$ trung bình 0, độ lệch chuẩn 1

Chọn k: kiểm định chéo

- Siêu tham số (k, độ đo khoảng cách) không học được từ tập huấn luyện
- Chia dữ liệu: huấn luyện / kiểm định / kiểm tra (VD 70 / 15 / 15); tập kiểm tra chỉ dùng một lần ở cuối
- Kiểm định chéo 5 phần: lần lượt lấy 1 phần làm kiểm định, 4 phần huấn luyện; lấy trung bình 5 lần







Biên quyết định: dữ liệu · **1-NN (nhạy nhiễu)** · **5-NN (trơn hơn)**

kNN: chi phí, ưu và nhược điểm

- N mẫu huấn luyện, M mẫu kiểm tra, d chiều:
  - Huấn luyện: O(1) (chỉ lưu dữ liệu)
  - Nhận dạng: O(M·N·d)
- Ưu điểm
  - Đơn giản, không cần huấn luyện
  - Hiệu quả tốt nếu đặc trưng tốt
- Nhược điểm
  - Nhận dạng chậm, tốn bộ nhớ
  - Kém khi số chiều lớn
  - Tăng tốc: cây k-d, tìm láng giềng xấp xỉ

MNIST: chữ số viết tay 28×28

Phương pháp	Lỗi (%)
Phân lớp tuyến tính	12,0
kNN, Euclid	5,0
kNN, Euclid, ảnh chỉnh nghiêng	2,4
kNN, khoảng cách tiếp tuyến	1,1
kNN, so khớp shape context	0,67
SVM đa thức bậc 4	1,1
CNN LeNet-5	0,8

Nguồn: Y. LeCun, MNIST database (60 000 ảnh huấn luyện, 10 000 ảnh kiểm tra); trích từ Thị giác máy tính – Bài 8

Mô hình túi từ (Bag-of-Words)

Ý tưởng từ xử lý văn bản

- Văn bản = vector đếm số lần xuất hiện của mỗi từ trong từ điển (bỏ qua thứ tự từ)
- Độ tương đồng hai văn bản: cosine

$$\cos(h_1, h_2) = h_1 \cdot h_2 \,/\, (\|h_1\| \cdot \|h_2\|)$$

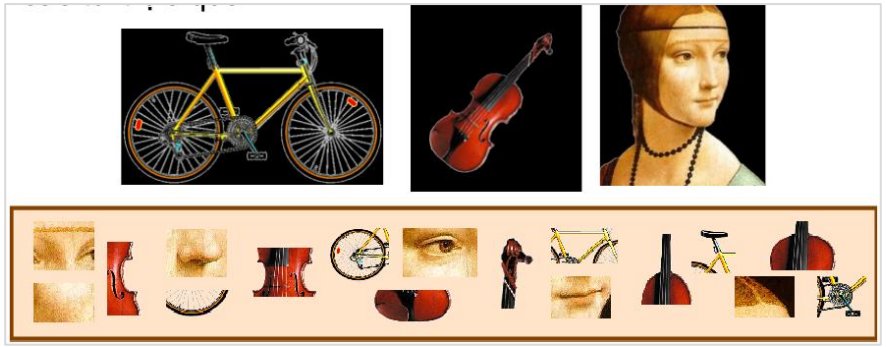
- Từ phổ biến ("và", "của") ít mang thông tin → trọng số TF-IDF:

$$w(t, d) = tf(t, d) \cdot \log(\, N \,/\, n_t \,)$$

Từ	tf trong văn bản d	Số văn bản chứa từ (N = 1000)	idf = $\log_{10}(N/n_t)$	tf · idf
"và"	20	1000	0	0
"robot"	5	10	2	10

Túi từ trực quan cho ảnh





Văn bản	Ảnh
Từ	Đặc trưng cục bộ đã lượng tử hóa = "từ trực quan" (visual word)
Từ điển	Bộ từ điển trực quan (codebook): K tâm cụm học bằng K-means
Vector đếm từ	Lược đồ K chiều: số đặc trưng rơi vào mỗi visual word

Ưu: bền với che khuất, bất biến tỉ lệ & phép quay (nhờ đặc trưng cục bộ)
Nhược: mất bố cục không gian → khắc phục: chia ảnh thành lưới (spatial pyramid)

Nguồn hình: Thị giác máy tính – Bài 8: Phân loại ảnh (theo K. Grauman, CS376, UT Austin; I. Gkioulekas, 16-385, CMU)

Quy trình mô hình túi từ trực quan

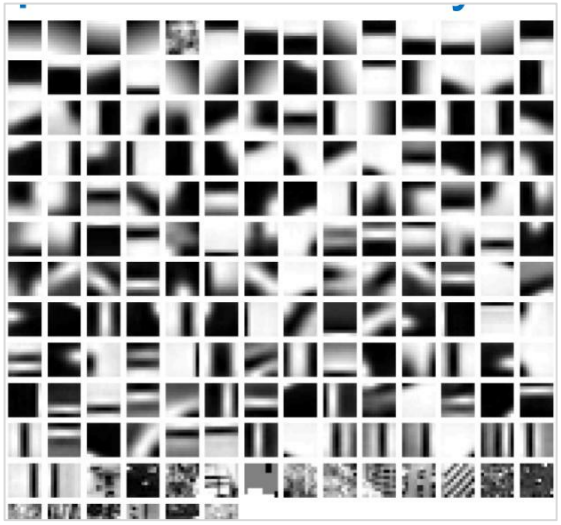
1. Học từ điển
Trích SIFT từ tập ảnh huấn luyện; K-means → K visual word

→

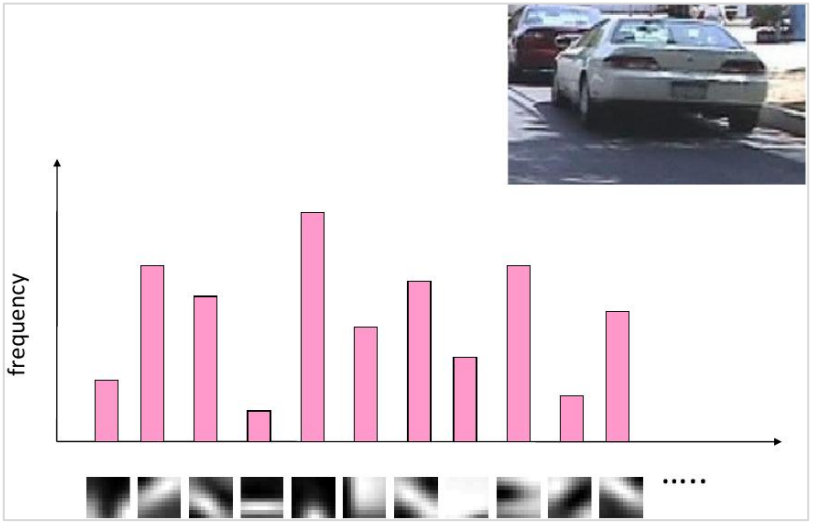
2. Mã hóa
Gán mỗi đặc trưng vào tâm gần nhất; đếm → lược đồ K chiều

→

3. Phân lớp
kNN, SVM, Naive Bayes trên vector BoW



Từ điển trực quan (mỗi ô: một tâm cụm)



Lược đồ visual word của một ảnh

K thường từ vài trăm đến vài nghìn; truy vấn CSDL lớn: hàng trăm nghìn – hàng triệu từ

Ví dụ: mã hóa ảnh thành vector BoW

Từ điển 4 từ (đặc trưng 2 chiều): w_1 (0; 0), w_2 (4; 0), w_3 (0; 4), w_4 (4; 4)

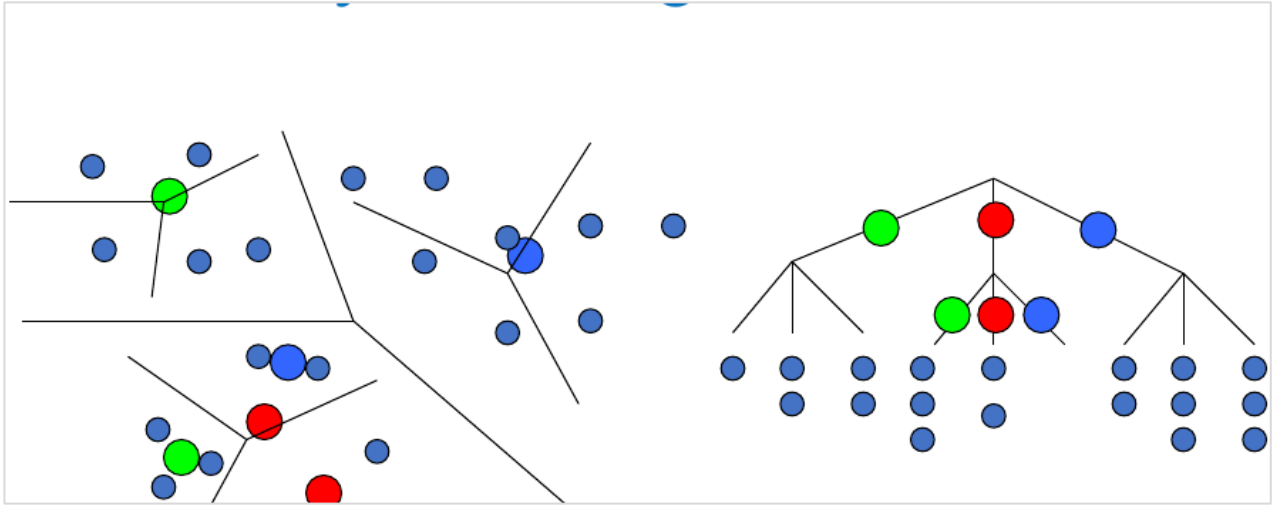
Đặc trưng của ảnh 1	(0,5; 0,2)	(3,6; 0,4)	(0,3; 3,9)	(4,2; 3,7)	(3,8; 4,1)	(0,1; 0,6)
Từ gần nhất	w_1	w_2	w_3	w_4	w_4	w_1

Ảnh	Lược đồ h	cos với ảnh 1
Ảnh 1	(2; 1; 1; 2)	1
Ảnh 2	(0; 1; 1; 4)	$10 / (\sqrt{10} \cdot \sqrt{18}) \approx 0{,}745$
Ảnh 3	(3; 1; 1; 1)	$10 / (\sqrt{10} \cdot \sqrt{12}) \approx 0{,}913$

Ảnh 3 giống ảnh 1 hơn ảnh 2 → nếu ảnh 3 có nhãn “mô tô”, 1-NN gán ảnh 1 là “mô tô”
Số đặc trưng mỗi ảnh khác nhau nhưng lược đồ luôn có $K = 4$ chiều

Cây từ vựng

Vocabulary tree (Nistér & Stewénius, CVPR 2006)



- K-means phân cấp: chia dữ liệu thành b cụm, mỗi cụm lại chia b cụm… sâu L mức
- Số visual word = b^L; VD b = 10, L = 6 → 1 000 000 từ
- Gán một đặc trưng: đi từ gốc xuống lá, mỗi mức so với b tâm → chỉ $b \cdot L = 60$ phép so sánh thay vì 1 000 000
- Kết hợp chỉ mục ngược (inverted index): mỗi từ lưu danh sách ảnh chứa nó → truy vấn CSDL hàng triệu ảnh

Đánh giá: ma trận nhầm lẫn
Confusion matrix

	Dự đoán: dương	**Dự đoán: âm**
Thực tế: dương	TP (dương thật)	FN (âm giả – bỏ sót)
Thực tế: âm	FP (dương giả – báo nhầm)	TN (âm thật)

- Lớp "dương" = lớp ta quan tâm phát hiện (VD hạt gãy, khối u, khuôn mặt)
- Nhiều lớp: ma trận $C \times C$, ô (i, j) = số mẫu lớp i bị dự đoán là lớp j; đường chéo = dự đoán đúng
- Ô ngoài đường chéo cho biết lớp nào hay bị nhầm với lớp nào (VD chữ số 4 ↔ 9)

Accuracy, Precision, Recall, F1

Độ đo	Công thức	Trả lời câu hỏi
Accuracy	(TP + TN) / (TP + TN + FP + FN)	Đoán đúng bao nhiêu phần trăm?
Precision	TP / (TP + FP)	Trong các mẫu báo dương, bao nhiêu là đúng?
Recall	TP / (TP + FN)	Trong các mẫu dương thật, tìm được bao nhiêu?
F1	2 · P · R / (P + R)	Trung bình điều hòa của precision và recall

Dữ liệu lệch lớp → accuracy dễ đánh lừa: dùng precision, recall, F1
Tăng ngưỡng báo dương → precision thường tăng, recall giảm (và ngược lại)
Recall còn gọi là độ nhạy (sensitivity, TPR)

Thuật toán nhận dạng theo cấu trúc

- Ngoài cách biểu diễn định lượng thì còn tồn tại kiểu đối tượng định tính
- Ví dụ mối quan hệ giữa các đối tượng hoặc dạng của đối tượng
- Giả sử đối tượng có thể được biểu diễn bởi một chuỗi ký tự và mỗi ký tự sẽ thể hiện một đặc tính
- Hàm phân biệt là hàm logic kiểm tra chuỗi có được sinh ra bởi tập quy tắc (văn phạm) của lớp hay không

Thuật toán nhận dạng theo cấu trúc

- Có hai giai đoạn trong quy trình nhận diện:
  - Xác định quy tắc xây dựng
  - Xác định các dạng dựa vào các quy tắc đó
- Trong hai giai đoạn thì xác định quy tắc xây dựng là rất khó khăn và là vấn đề chính cần giải quyết trong quy trình nhận diện dạng này

Nhận diện dựa trên mạng Nơron

- Mạng nơron bao gồm nhiều phần tử xử lý đơn giản hoạt động song song.
- Tính năng của hệ thống phụ thuộc vào cấu trúc liên kết giữa các nơron và trọng số của các liên kết này
- Mạng nơ ron có thể học từ dữ liệu mẫu và tổng quát hóa dựa trên các dữ liệu mẫu học. Bản chất quá trình học là việc hiệu chỉnh các tham số của các nơ ron để đầu mạng dự đoán đúng dữ liệu học.
- Trong mạng nơ ron, các nơ ron đón nhận tín hiệu vào gọi là nơ ron vào và các nơ ron đưa thông tin ra gọi là nơ ron ra.

Mạng Nơron

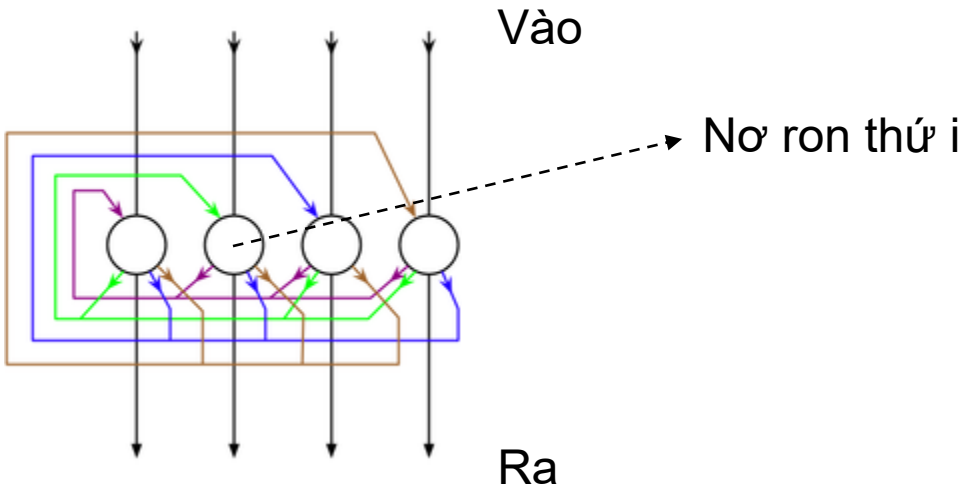
Mạng Hopfield

- Mạng Hopfield là mạng nơ ron 1 lớp
- Ánh xạ dữ liệu tín hiệu vào sang tín hiệu ra theo kiểu tự kết hợp
- Nếu tín hiệu vào là X thuộc miền D thì tín hiệu ra Y cũng thuộc miền D
- Mạng Hopfield mô phỏng khả năng hồi tưởng của não người (nhận ra người quen khi nhận ra các nét quen trên khuôn mặt)

Mạng Nơron

Mạng Hopfield

- Mạng Hopfield có một lớp ra có kích thước bằng kích thước tín hiệu vào, liên kết nơ ron là đầy đủ.
- Mạng Hopfield yêu cầu tín hiệu vào có giá trị lưỡng cực -1 và 1



Mạng Nơron

Mạng Hopfield

- Hàm kích hoạt tại các nơ ron là hàm dấu:

$$out_j = sign(Net_j) = sign\left(\sum_{i=1}^{m} w_{ji} x_i\right)$$

w_{ij} là trọng số của liên kết giữa nơ ron thứ i với nơ ron thứ j

Mạng Nơron

Mạng Hopfield

- Học theo luật Hebb từ p mẫu cho trước
- Giả sử có p mẫu học tương ứng với các vector tín hiệu vào X_s, s = 1..p
- Mạng cần xác định bộ trọng số W sao cho

$$X_s = f(X_s, W) \text{ với mọi } s = 1..p$$

- Ta xây dựng ma trận trọng số W như sau:

$$w_{ij} = \begin{cases} \sum_{s=1}^{p} x_{sj} x_{si}, i \neq j \\ 0, i = j \end{cases}$$

Mạng Nơron

- **Mạng Hopfield**: Hồi tưởng (nhận dạng)
  - Giả sử đưa vào mạng vector tín hiệu X
  - Việc tính toán đầu ra Y cho tín hiệu X là quá trình lặp lại:
    - Đặt $X_0 = X$
    - Tính Y_t là tín hiệu đầu ra tương ứng với X_t lan truyền trong mạng một lần
    - Nếu Y_t khác X_t thì tiếp tục với t = t+1 và $X_{t+1} = Y_t$
    - Nếu $Y_t = X_t$ thì dừng lại và kết quả của mạng là Y_t
    - W không thay đổi trong quá trình tính Y

Ví dụ: hồi tưởng với mạng Hopfield

Mẫu đã lưu $X^1 = (1, -1, 1, -1)$; $w_{ij} = x^1_i \cdot x^1_j$ $(i \neq j)$, $w_{ii} = 0$

Ma trận W

0	−1	1	−1
−1	0	−1	1
1	−1	0	−1
−1	1	−1	0

Cập nhật đồng bộ

t	X_t	Net = $W \cdot X_t$	Y_t = sign(Net)
0	(1, 1, 1, −1)	(1, −3, 1, −1)	(1, −1, 1, −1)
1	(1, −1, 1, −1)	(3, −3, 3, −3)	(1, −1, 1, −1)

$Y_1 = X_1 \rightarrow$ dừng; điểm ảnh thứ 2 bị nhiễu đã được sửa

- Nơ ron 2 nhận Net = −3: cả 3 nơ ron còn lại cùng "bỏ phiếu" −1 → lật lại dứt khoát
- Cập nhật không đồng bộ (mỗi lần một nơ ron) luôn hội tụ khi W đối xứng, $w_{ii} = 0$; cập nhật đồng bộ có thể dao động

Mạng Hopfield

Hàm năng lượng và sức chứa

- Hàm năng lượng

$$E(X) = -\frac{1}{2} \sum_i \sum_j w_{ij} \cdot x_i \cdot x_j$$

  - Cập nhật không đồng bộ: mỗi lần lật một nơ ron theo hàm dấu → E không tăng → mạng luôn dừng ở một cực tiểu
  - Ví dụ trên: E(1, 1, 1, −1) = 0 → E(1, −1, 1, −1) = −6
  - Mẫu đã học = cực tiểu (điểm hút); trạng thái giả = cực tiểu không mong muốn; −X cũng là cực tiểu
- Sức chứa (luật Hebb, mẫu ngẫu nhiên)
  - Khoảng 0,138 · N mẫu; N = 100 nơ ron → khoảng 13 mẫu
  - Mẫu càng giống nhau (tương quan cao) → sức chứa càng giảm
  - Số trọng số tăng theo N²: ảnh 10×10 → 4 950 trọng số độc lập

Mạng Nơron

- Mạng Hopfield: Một số tình huống nảy sinh trong huấn luyện mạng
  - Mạng không dừng:
    - Mạng có thể đưa ra luân phiên một vài mẫu học hoặc ảnh ngược của chúng
  - Mạng dừng và $X_t = X$
    - X đã được đoán đúng dựa trên mẫu học, X có thể là một trong các mẫu đã học

Mạng Nơron

- Mạng Hopfield: Một số tình huống nảy sinh trong huấn luyện mạng
  - Mạng dừng với X_t là X_s nào đó trong mẫu đã học
    - Mạng đã phục hồi nguyên dạng của X chính là X_s
  - Mạng dừng với X_t không thuộc mẫu đã học
    - Chỉ ra một vector mới có thể dùng để cập nhật trọng số
  - Mạng dừng với X_t là ảnh ngược ở trên.

Mạng Nơron

Mạng Kohonen

Bản đồ Kohonen hoặc bản đồ tự tổ chức

- Mạng Kohonen tập trung vào mối liên hệ có tính cấu trúc trong các vùng lân cận hoặc trong toàn thể không gian mẫu
- Trong mạng Kohonen các vector tín hiệu vào gần nhau sẽ được ánh xạ sang các nơ ron trong mạng lân cận nhau

Mạng Nơron

Mạng Kohonen

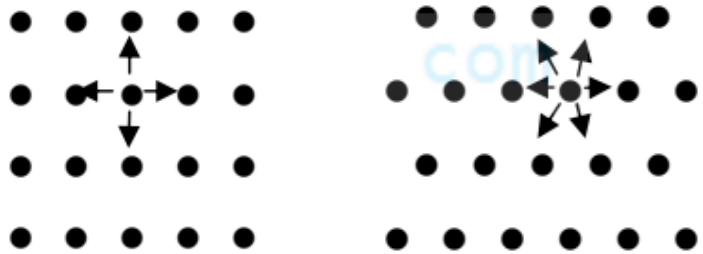
Bản đồ Kohonen hoặc bản đồ tự tổ chức

- Mạng Kohonen rất gần với mạng sinh học về cấu tạo lẫn cơ chế học
- Mạng Kohonen có một lớp kích hoạt là các nơ ron được phân bố trong mặt phẳng hai chiều kiểu lưới vuông hoặc lục giác
- Mỗi nơ ron bên trong lưới có cùng số láng giềng; các đầu vào tương tự sẽ kích hoạt các nơ ron gần nhau (có thể cuộn lưới thành hình xuyến để bỏ hiệu ứng biên)

Mạng Nơron

Mạng Kohonen

Bản đồ Kohonen hoặc bản đồ tự tổ chức



Lưới các nơ ron trong mặt phẳng 2 chiều

Mạng Nơron

Mạng Kohonen

Bản đồ Kohonen hoặc bản đồ tự tổ chức

- Tất cả các nơ ron ở lớp kích hoạt được nối đầy đủ với lớp vào và mỗi kết nối này sẽ có một trọng số
- Các nơ ron trên lớp kích hoạt chỉ liên hệ với các nơ ron lân cận nên khi có tín hiệu đầu vào sẽ chỉ tạo ra kích hoạt địa phương
- Vùng được kích hoạt sẽ chỉ ra vị trí của tín hiệu đầu vào trong không gian đối tượng

Mạng Kohonen

Bản đồ Kohonen hoặc bản đồ tự tổ chức

- Việc học của mạng kohonen dựa trên kỹ thuật cạnh tranh không cần mẫu học.
- Trọng số của các nơ ron được khởi tạo bằng một số nhỏ, bất kỳ
- Mạng được học qua một lượng lớn mẫu gần nhau và thường nhiều lần theo các vòng lặp
- Tại một thời điểm chỉ có một nơ ron duy nhất C trong lớp kích hoạt được lựa chọn với nguyên tắc là nơ ron C có vector trọng số gần với tín hiệu vào nhất

Mạng Nơron

Mạng Kohonen

Bản đồ Kohonen hoặc bản đồ tự tổ chức

- Sau khi có nơron C, các trọng số w_{ci} được hiệu chỉnh nhằm cho gần với trọng số mong muốn (đầu vào)
- Trọng số được kéo về phía tín hiệu vào: thành phần wci lớn hơn xsi thì giảm, nhỏ hơn thì tăng, tỉ lệ với độ chênh lệch

Mạng Kohonen

Bản đồ Kohonen hoặc bản đồ tự tổ chức

- Tỉ lệ thay đổi trọng số nhỏ dần theo thời gian (α(s)) và theo khoảng cách trên lưới giữa nơ ron v và nơ ron thắng u (θ(u,v,s)):

$$w_v(s+1) = w_v(s) + \theta(u,v,s)\alpha(s)(D(t) - w_v(s))$$

- Với:
  - s là thứ tự bước
  - D(t) là vector đầu vào t
  - u là số thứ tự của nơ ron C được chọn
  - θ(u,v,s) là hàm tỷ lệ khoảng cách giữa nơ ron v
  - và u (có thể là hàm ngưỡng hoặc hàm Gaussian)

Ví dụ: một bước cập nhật SOM

Đầu vào x = (0,8; 0,2); α = 0,5; nơ ron thắng A; B là láng giềng của A trên lưới

Nơ ron	w cũ	$\|x - w\|^2$	θ(u, v)	α·θ	w mới = w + α·θ·(x − w)
A (thắng)	(0,5; 0,5)	0,18	1	0,5	(0,65; 0,35)
B (láng giềng)	(0,4; 0,6)	0,32	0,5	0,25	(0,50; 0,50)
C (ở xa)	(0,1; 0,9)	0,98	0	0	(0,1; 0,9)

- A tiến về x một nửa quãng đường; B tiến theo một phần tư; C đứng yên
- Sau cập nhật: $\|x - A\|^2$ giảm từ 0,18 xuống 0,045 → lần sau A thắng dứt khoát hơn
- B "kế thừa" vị trí cũ của A → các nơ ron cạnh nhau mang trọng số giống nhau → bản đồ hình thành

Thuật toán huấn luyện SOM

- 1. Khởi tạo ngẫu nhiên (nhỏ) các vector trọng số w_v
- 2. Lấy một mẫu D(t) từ tập dữ liệu
- 3. Tìm nơ ron thắng: u = argmin_v ‖D(t) − w_v‖
- 4. Cập nhật mọi nơ ron: w_v ← w_v + θ(u, v, s) · α(s) · (D(t) − w_v)
- 5. Giảm α(s) và bán kính σ(s); lặp lại từ bước 2

Thành phần	Dạng thường dùng
Hàm lân cận	θ(u, v, s) = exp(−‖r_u − r_v‖² / (2σ(s)²)), r: tọa độ nơ ron trên lưới
Tốc độ học	$\alpha(s) = \alpha_0 \cdot \exp(-s / T)$, VD $\alpha_0 = 0{,}5$
Bán kính	$\sigma(s) = \sigma_0 \cdot \exp(-s / T)$, $\sigma_0 \approx$ nửa kích thước lưới

Mạng Nơron

Mạng Kohonen

Bản đồ Kohonen hoặc bản đồ tự tổ chức

- Mạng Kohonen được huấn luyện dựa vào sự kích hoạt địa phương và các nơ ron lân cận nên các đối tượng gần nhau sẽ kích hoạt các nơ ron gần nhau
- Khi chuyển một tín hiệu đầu vào vào mạng thì một vùng nơ ron sẽ được kích hoạt cho chúng ta thấy tín hiệu đầu vào này thuộc vùng dữ liệu nào

Từ mạng nơ ron cổ điển đến CNN

- Đặc trưng thủ công (GLCM, Hu, SIFT, BoW) → đặc trưng học tự động từ dữ liệu
- Lớp tích chập
  - Bộ lọc F×F×C trượt trên ảnh (như lọc không gian ở chương 3) + hàm kích hoạt ReLU
  - Kích thước ra: (N − F + 2P) / S + 1
  - VD ảnh 32×32×3, 6 bộ lọc 5×5, P = 0, S = 1 → 28×28×6; số tham số 6 × (5·5·3 + 1) = 456
- Lớp pooling
  - Max / average trên cửa sổ 2×2, bước 2 → giảm một nửa kích thước (28 → 14)
- Huấn luyện
  - Lan truyền ngược trên hàng chục nghìn – hàng triệu ảnh có nhãn
  - Học chuyển giao: tinh chỉnh mạng đã huấn luyện sẵn cho bài toán mới, ít dữ liệu

So sánh các phương pháp

Phương pháp	Kiểu học	Số lớp / cụm	Ý tưởng chính	Lưu ý
K-means	Không giám sát	Cho trước K	Gán điểm – tính lại tâm	Nhạy khởi tạo, ngoại lai
Khoảng cách lớn nhất	Không giám sát	Theo ngưỡng θ	Phần tử xa nhất → tâm mới	Nhạy điểm nhiễu
ISODATA	Không giám sát	Tách / gộp	K-means + tách + gộp	Nhiều tham số
Mean-Shift	Không giám sát	Theo bán kính h	Dịch cửa sổ tới đỉnh mật độ	Chậm, phụ thuộc h
kNN	Có giám sát	Theo nhãn mẫu	Bỏ phiếu k láng giềng	Nhận dạng chậm
Cấu trúc	Theo quy tắc	Theo văn phạm	Chuỗi ký hiệu + phân tích cú pháp	Khó xây quy tắc
Hopfield	Luật Hebb	Số mẫu lưu	Bộ nhớ liên kết, lặp tới ổn định	Sức chứa ≈ 0,138N
Kohonen (SOM)	Không giám sát	Kích thước lưới	Học cạnh tranh + láng giềng	Bảo toàn quan hệ lân cận

Tóm tắt

- Nhận dạng ảnh: bài toán, thách thức, hệ thống nhận dạng
  - Học có giám sát và không giám sát
- Trích chọn đặc trưng: màu, kết cấu, hình dạng, cục bộ
- Nhận dạng dựa theo không gian
  - K-means, khoảng cách lớn nhất, ISODATA, Mean-Shift
  - k láng giềng (kNN), mô hình túi từ, đánh giá
- Nhận dạng theo cấu trúc
- Một số mô hình mạng nơ ron
  - Mạng Hopfield, mạng Kohonen, hướng tới CNN